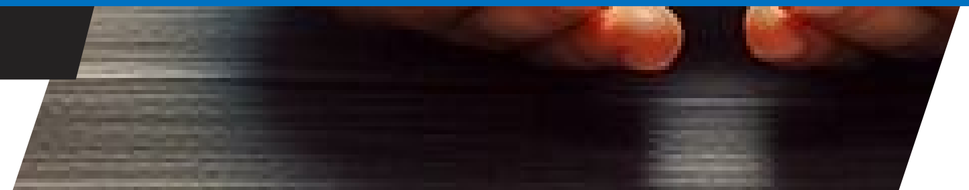


Klasifikasi Persepsi Publik terhadap Peluang Kerja Penyandang Disabilitas Tunarungu di Indonesia Menggunakan Stacking Ensemble

Dafina Ramadhani (23083010030)
Mujtahida Azmi Fitri (23083010036)



LATAR BELAKANG

Persepsi publik berperan penting dalam membentuk keputusan rekrutmen terhadap penyandang disabilitas, karena anggapan di masyarakat memengaruhi penilaian atas kelayakan kerja seseorang. Kesenjangan ini terlihat pada rendahnya partisipasi kerja penyandang disabilitas, meskipun UU No. 8 Tahun 2016 telah mewajibkan kuota 1% di perusahaan swasta dan 2% di instansi pemerintah. Bagi penyandang tunarungu, hambatan komunikasi dan stigma membuat eksklusi semakin nyata. Komentar YouTube menjadi ruang diskusi organik yang memuat dukungan sekaligus penolakan, sehingga penelitian ini mengklasifikasikannya menjadi Inklusi dan Eksklusi menggunakan Stacking Ensemble.

DATA

- Sumber data: komentar YouTube.
- Pengumpulan data menggunakan YouTube Data API v3.
- Data dikumpulkan dari 31 video yang berkaitan dengan isu tunarungu/disabilitas dan pekerjaan.
- Data awal: 14.505
- Data final: 2.920



PELABELAN DATA

Pelabelan dilakukan secara otomatis dengan Gemini API (model gemini-3.5-flash-lite). Prompt menempatkan Gemini sebagai annotator penelitian persepsi publik terhadap peluang kerja tunarungu, berisi definisi Inklusi dan Eksklusi

Inklusi – 2.110 komentar (72,3%)

Komentar yang menunjukkan dukungan, penerimaan, pengakuan kemampuan, atau pandangan yang membuka kesempatan kerja bagi penyandang tunarungu.

Eksklusi – 810 komentar (27,7%)

Komentar yang menunjukkan penolakan, diskriminasi, stereotip, atau pandangan yang membatasi kesempatan kerja penyandang tunarungu.

DATA WRANGLING DAN PREPROCESSING

Case folding

Mengubah huruf menjadi kecil dan menangani normalisasi Unicode.

Cleaning

Menghapus URL, mention, emoji, tanda baca, dan karakter yang tidak diperlukan.

Tokenization

Memecah kalimat menjadi token/kata.

Normalization

Mengubah kata tidak baku menjadi bentuk yang lebih baku.

Stopword removal

Menghapus kata umum sambil mempertahankan kata negasi penting.

Stemming

Mengubah kata ke bentuk dasar menggunakan Sastrawi.

TF-IDF

TF-IDF digunakan untuk mengubah komentar berbentuk teks menjadi representasi numerik yang dapat diproses oleh model machine learning.

- N-gram: unigram, yaitu fitur berupa satu kata.
- min_df=2: kata harus muncul pada minimal dua dokumen.
- sublinear_tf=True: frekuensi kata dihitung menggunakan skala logaritmik.

hasil:

- Jumlah dokumen: 2.920.
- Jumlah fitur: 1.856.
- Ukuran matriks TF-IDF: 2.920 × 1.856.



PEMBAGIAN DATA TRAINING DAN TESTING

Data dibagi menjadi 80% data training dan 20% data testing menggunakan stratified split agar proporsi kelas tetap terjaga.

Data	Jumlah
Training	2336
Testing	584
Total	2920

Distribusi label pada data training:

- Inklusi: 1.688.
- Eksklusi: 648.

Distribusi label pada data testing:

- Inklusi: 422.
- Eksklusi: 162.

Karena jumlah kelas Inklusi lebih banyak daripada Eksklusi, digunakan class_weight='balanced' pada SVM dan Logistic Regression, serta scale_pos_weight sekitar 2,60 pada XGBoost. Tuning parameter dilakukan menggunakan 5-fold cross-validation pada data training.

HASIL PEMODELAN SVM DAN XGBOOST

Model SVM dan XGBoost dilatih menggunakan fitur TF-IDF dari data training, kemudian diuji pada 584 komentar data testing.

Model	Akurasi	Presisi (macro)	Recall (macro)	F1 (macro)	F1 eksklusi
SVM	0.8288	0.7854	0.8036	0.7933	0.7076
XGBoost	0.8082	0.761	0.7741	0.7668	0.6686

SVM menghasilkan accuracy dan F1-Macro lebih tinggi dibandingkan XGBoost pada data uji. Kedua model kemudian digunakan sebagai base learner dalam Stacking Ensemble untuk melihat apakah penggabungan model dapat meningkatkan performa klasifikasi

PEMBENTUKAN STACKING ENSEMBLE

Stacking Ensemble dibangun dengan menggabungkan dua model dasar, yaitu SVM dan XGBoost. Logistic Regression digunakan sebagai meta-learner untuk mempelajari cara menggabungkan keluaran kedua model.

Model Stacking menghasilkan prediksi akhir dengan memanfaatkan keluaran kedua base learner. Penggunaan prediksi out-of-fold membantu menyediakan data pelatihan bagi meta-learner tanpa menggunakan prediksi pada data training yang sama secara langsung.

HASIL STACKING ENSEMBLE

Model Stacking dievaluasi pada 584 komentar data testing. Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas.

Hasil Evaluasi

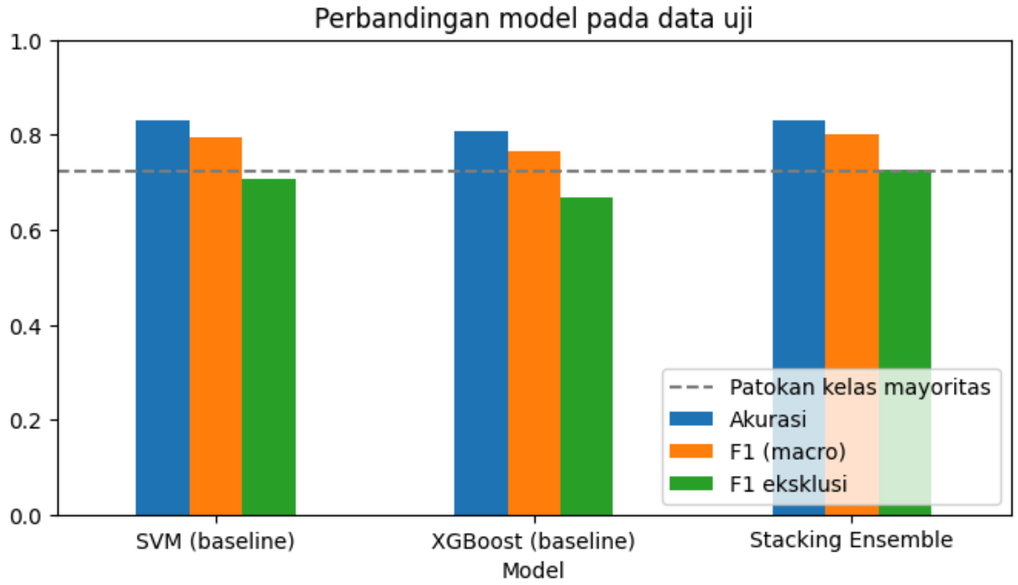
- Accuracy: 82,88%
- Precision Macro: 78,78%
- Recall Macro: 82,64%
- F1-Macro: 80,10%

Metrik	Inklusi	Eksklusi
Precision	9,237%	6,520%
Recall	8,318%	8,210%
F1-Score	8,753%	7,268%

Precision kelas Inklusi lebih tinggi dibandingkan kelas Eksklusi. Artinya, prediksi Inklusi lebih sering benar dibandingkan prediksi Eksklusi. Terdapat 100 prediksi salah dari 584 komentar atau sekitar 17,1%, sehingga model masih perlu ditingkatkan.

PERBANDINGAN PERFORMA MODEL

Ketiga model dibandingkan menggunakan data testing yang sama berdasarkan accuracy, F1-Macro, dan F1 kelas Eksklusi.



Hasil Perbandingan

- SVM menghasilkan accuracy 82,88% dan F1-Macro 79,33%.
- XGBoost menghasilkan accuracy 80,82% dan F1-Macro 76,68%.
- Stacking menghasilkan accuracy 82,88% dan F1-Macro 80,10%.

Stacking menghasilkan F1-Macro dan F1 Eksklusi tertinggi. Accuracy-nya sama dengan SVM, sehingga peningkatan Stacking terlihat pada keseimbangan performa klasifikasi, bukan pada accuracy.

SARAN

Penelitian selanjutnya dapat memperluas sumber dan jumlah data, meningkatkan kualitas pelabelan, serta mencoba metode representasi teks atau model klasifikasi lain untuk meningkatkan performa pada kelas Eksklusi.



THANK YOU